

פתרון מבחן מסכם, מועד ב'

שיטות סטטיסטיות בהנדסה ומדעי המחשב

15.8.22

נוסחאות שימושיות

- נגזרת של תבנית ריבועית:

$$\frac{\partial (c - bx)^T A (c - bx)}{\partial x} = b^T (A + A^T) (c - bx)$$

כאשר $x \in \mathbb{R}$ ו- $c \in \mathbb{R}^{n \times 1}$, $b \in \mathbb{R}^{n \times 1}$, $A \in \mathbb{R}^{n \times n}$

- החלפת משתנים: אם $Y = g(x)$ אז:

$$f_Y(y) = \sum_i \frac{f_X(x_i)}{|g'(x_i)|}$$

כאשר x_i הם הפתרונות של המשוואה $y = g(x)$

- התפלגות נורמלית:

$$f_X(x) = \frac{1}{(2\pi)^{d/2} \sqrt{|\det(\Sigma)|}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$$

- התפלגות פואסון $N \sim \text{Poisson}(\lambda)$

$$P(N = k) = \frac{(\lambda)^k}{k!} e^{-\lambda}$$

$$\mathbb{E}[N] = \text{Var}(N) = \lambda$$

- התפלגות בינומית $X \sim \text{Binomial}(n, p)$

- הסתברות:

$$p_X(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

- תוחלת:

$$\mathbb{E}[X] = np$$

שאלה 1 (37 נקודות)

יהי w וקטור גאוס $w \sim N(0, Q)$ כאשר Q ידוע. יהי y אות מורעש:

$$y = h\theta + w$$

כאשר h וקטור דטרמינסטי ידוע עם איברים שונים מ-0, ו- θ הוא סקאלר דטרמינסטי לא ידוע.

1. חשבו משערך maximum-likelihood ל- θ על סמך מדידות y .

2. ומצאו משערך least-squares ל- θ

(א) על הבעיה המקורית, ונסמן אותו ב- $\hat{\theta}_{rls}$

(ב) קודם תלבינו את הרעש ע"י הכפלה של הבעיה ב- $Q^{-\frac{1}{2}}$ ואחר כך תפתרו least-squares על הבעיה החדשה, נסמן את המשערך ב- $\hat{\theta}_{wls}$

3. איזה מהמשערכים מסעיף 2 מתכלד עם המשערך מסעיף 1? הסבירו למה.

4. חשבו את ההטייה והשונות של כל אחד המשערכים מסעיף 2.

5. איזה משערך יותר טוב? (רמז: ניתן לענות גם בלי חישוב).

6. האם יכול להיות משערך מוטא בעל שונות נמוכה יותר עבור θ מסוים?

פתרון

1. ה-likelihood נתון ע"י:

$$L(\theta) = \frac{1}{2\pi \det(C)^{1/2}} e^{-\frac{1}{2}(y-h\theta)^T Q^{-1}(y-h\theta)}$$

נוציא log :

$$LL = -\log \left(2\pi \det(C)^{1/2} \right) - \frac{1}{2} (y - h\theta)^T Q^{-1} (y - h\theta)$$

נגזור ונשווה ל-0, נשתמש בנוסחא:

$$\begin{aligned} \frac{\partial LL}{\partial \theta} &= \frac{1}{2} h^T (Q^{-1T} + Q^{-1}) (y - h\theta) = \\ &= h^T Q^{-1} (y - h\theta) = 0 \end{aligned}$$

כאשר השתמשנו בכך ש- C^{-1} סימטרית. לכן:

$$\begin{aligned} h^T Q^{-1} y &= h^T Q^{-1} h \theta \\ \theta &= (h^T Q^{-1} h)^{-1} h^T Q^{-1} y \end{aligned}$$

2. משעריך ה-least squares

(א) על הבעיה המקורית:

$$\hat{\theta}_{rls} = (h^T h)^{-1} h^T y$$

(ב) אחרי הלבנת רעש ע"י הכפלה ב $A = Q^{-0.5}$ נקבל:

$$\tilde{y} = Ay = Ah\theta + Aw$$

$$\mathbb{E}[\tilde{y}] = \mathbb{E}[Ah\theta + Aw] = Ah\theta + A\mathbb{E}[w] = Ah\theta$$

$$\mathbb{V}ar(\tilde{y}) = \mathbb{V}ar(Ah\theta + Aw) = A\mathbb{V}ar(w)A^T = Q^{-0.5}QQ^{-0.5} = I$$

$$\hat{\theta}_{wls} = ((Ah)^T Ah)^{-1} (Ah)^T \tilde{y} = (h^T A^T Ah)^{-1} h^T A^T Ay = (h^T Q^{-1} h)^{-1} h^T Q^{-1} y$$

3. המשעריך השני מתלכד עם המשעריך מסעיף א' מכיוון שמשעריך least-squares שווה למשעריך maximum-likelihood בבעיית גרסיה לינארית עם רעש גאوسی לבן.

4. התוחלת של משעריך $\hat{\theta}_{rls}$ היא:

$$\mathbb{E}[\hat{\theta}_{rls}] = \mathbb{E}\left[(h^T h)^{-1} h^T y\right] = (h^T h)^{-1} h^T \mathbb{E}[y] = (h^T h)^{-1} h^T h\theta = \theta$$

לכן המשעריך חסר הטייה. השונות שלו נתונה ע"י

$$\mathbb{V}ar(\hat{\theta}_{rls}) = (h^T h)^{-1} h^T \mathbb{C}ov(y) h (h^T h)^{-1} = (h^T h)^{-1} h^T Q h (h^T h)^{-1}$$

התוחלת של משעריך $\hat{\theta}_{wls}$ היא:

$$\begin{aligned} \mathbb{E}[\hat{\theta}_{wls}] &= \mathbb{E}\left[(H^T Q^{-1} H)^{-1} H^T Q^{-1} y\right] = (H^T Q^{-1} H)^{-1} H^T Q^{-1} \mathbb{E}[y] \\ &= (H^T Q^{-1} H)^{-1} H^T Q^{-1} H\theta = \theta \end{aligned}$$

כלומר המשעריך חסר הטייה. השונות של המשעריך נתונה ע"י

$$\begin{aligned} \mathbb{V}ar(\hat{\theta}_{wls}) &= (h^T Q^{-1} h)^{-1} h^T Q^{-1} COV(y) Q^{-1} h (h^T Q^{-1} h)^{-1} = \\ &= (h^T Q^{-1} h)^{-1} h^T Q^{-1} Q Q^{-1} h (h^T Q^{-1} h)^{-1} = \\ &= (h^T Q^{-1} h)^{-1} h^T Q^{-1} h (h^T Q^{-1} h)^{-1} = \\ &= (h^T Q^{-1} h)^{-1} \end{aligned}$$

5. שני המשערכים הם לינאריים חסרי הטייה. לפי משפט גאוס-מרקוב, משעריך ה-least-squares הוא בעל השונות הנמוכה ביותר מבין המשערכים הלינאריים חסרי הטייה, לבעיה של מדידות חסרות קורלציה, כלומר לבעיה אחרי ההכפלה ב A לכן בהכרח המשעריך $\hat{\theta}_{wls}$ יהיה בעל שונות נמוכה יותר ולכן יהיה טוב יותר (עי שניהם חסרי הטייה)

6. כן. למשל עבור $\theta = 0$ המשעריך $\hat{\theta} = 0$ יהיה טוב יותר.

שאלה 2 (33 נקודות)

נתונה בעיית בחינת ההשערות הבאה:

$$H_0 : x = w$$

$$H_1 : x = s + w$$

כאשר

$$w \sim N(0, 1), \quad s \sim N(0, \sigma^2)$$

s ו- w בלתי תלויים סטטיסטית ו- σ^2 ידוע.

שימו לב! הקלט לגלאי הוא מדידה בודדת x

- מצאו את גלאי LRT ופשטו את הביטוי ככל הניתן.
- מצאו את פונקציית צפיפות ההסתברות של הגלאי תחת שתי ההיפוטזות
- כתבו ביטוי (ניתן להשאיר בצורה אינטגרלית, אך σ לא יכול להופיע בו אלא רק בגבולות) לרמת התרעות השווא והסתברות הגילוי של הגלאי כפונקציה של הסף γ .
- בסעיף זה σ^2 לא ידוע. האם קיים גלאי אופטימלי לכל ערך של σ^2 ?
- התברר בדיעבד, שההתפלגות של האות s היא:

$$Pr(s) = \begin{cases} \frac{1}{2} & s = 1 \\ \frac{1}{2} & s = -1 \end{cases}$$

המנהלת שלכם לא מרשה לשנות את הגלאי אלא רק את הסף. האם תרצו לשנות את הסף על מנת לשמור על אותה רמה של התרעות שווא?

פתרון

1. נשים לב ש:

$$p(x; H_0) = N(0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$$
$$p(x; H_1) = N(0, 1 + \sigma^2) = \frac{1}{\sqrt{2\pi(1 + \sigma^2)}} e^{-\frac{1}{2(1 + \sigma^2)}x^2}$$

לכן:

$$T(y) = \frac{\frac{1}{\sqrt{2\pi(1 + \sigma^2)}} e^{-\frac{1}{2(1 + \sigma^2)}y^2}}{\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y^2}} \geq \gamma$$

נוציא $\log$ ונוריד קבועים:

$$T(y) = \frac{1}{2} \left(1 - \frac{1}{1 + \sigma^2} \right) x^2 \geq \gamma$$

נשים לב $\sigma^2 > 0$ לכן $(1 - \frac{1}{1 + \sigma^2}) > 0$ ולכן אפשר לחלק בו, ונקבל

$$T(x) = x^2 \geq \gamma$$

ניתן אף לכתוב את המבחן ע"י

$$T(x) = |x| \geq \gamma$$

(לא הורדנו ניקוד למי ששמרו על הצורה הריבועית)

2. נשים לב שבשתי ההיפוטזות y מתפלג נורמלית (נסמן את השונות שלהם ב σ_j^2) ונמצא את ההתפלגות של $t = |x|$, נשמתש בנוסחא להחלפת משתנים:

$$f_T(t) = \sum_i \frac{f_Y(x_i)}{|g'(xy)|}$$

נשים שלכל $t > 0$ יש 2 שמתאימים: $y_1 = t, y_2 = -t$ ולכן $g(x_1) = t, g(x_2) = -t$ כלומר

$$f(x_1) = \frac{1}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{x_1^2}{2\sigma_j^2}}, \quad g(x_1) = 1$$

$$f(x_2) = \frac{1}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{x_2^2}{2\sigma_j^2}}, \quad g(x_2) = -1$$

לכן

$$f_T(t) = \frac{\frac{1}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{t^2}{2\sigma_j^2}}}{1} + \frac{\frac{1}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{(-t)^2}{2\sigma_j^2}}}{|-1|} = \frac{2}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{t^2}{2\sigma_j^2}}$$

עבור $t < 0$ אין שום y שמתאים לכן הצפיפות מתאפסת. בסך הכל, מקבלים:

$$f_T(t; H_j) = \begin{cases} \frac{2}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{t^2}{2\sigma_j^2}} & t > 0 \\ 0 & t < 0 \end{cases}$$

כאשר

$$\sigma_j^2 = \begin{cases} 1 & j = 0 \\ 1 + \sigma^2 & j = 1 \end{cases}$$

נקודה עדינה לגבי $t = 0$ - לא עשינו את החישוב בנקודה כי הנגזרת שם לא הייתה מוגדרת, אבל ניתן לראות שהאינטגרל על הפונקציה הוא 1 ולכן הערך בנקודה $t = 0$ הוא סופי ולכן הוא לא חשוב.
 הערה: ניתן היה לפתור גם עבור המבחן $T(x) = x^2$ ולעבוד עם הדוגמא שראינו בהרצאה להחלפת משתנים.

3. קודם כל נשים לב שיש משמעות רק ל $\gamma > 0$ כי עבור $\gamma < 0$ נקבל שתמיד הגלאי אומר כן, ולכן קצב התרעות השווא והסתברות הגילוי יהיו 1. עבור $\gamma > 0$ נקבל:

• התרעות השווא:

$$f_{FA} = Pr(t > \gamma; H_0) = \int_{\gamma}^{\infty} f_T(t; H_0) = \frac{2}{\sqrt{2\pi}} \int_{\gamma}^{\infty} e^{-\frac{t^2}{2}} dt = 2Q(\gamma)$$

• הסתברות גילוי:

$$f_D = Pr(t > \gamma; H_1) = \int_{\gamma}^{\infty} f_T(t; H_1) = \frac{2}{\sqrt{2\pi(1+\sigma^2)}} \int_{\gamma}^{\infty} e^{-\frac{t^2}{2(1+\sigma^2)}} dt =$$

נעשה החלפת משתנים $t' = \frac{t}{\sqrt{1+\sigma^2}}$ ונקבל:

$$f_D = \frac{2}{\sqrt{2\pi}} \int_{\gamma/\sqrt{1+\sigma^2}}^{\infty} e^{-\frac{t'^2}{2}} dt' = 2Q\left(\frac{\gamma}{\sqrt{1+\sigma^2}}\right)$$

4. נשים לב שגלאי LRT שקיבלנו לא תלוי ב σ ולכן הוא אופטימלי לכל ערך של σ .

5. נשים לב שההסתברות להתרעת שווא תלויה רק בפילוג של הגלאי עבור H_0 ולכן לא תישאר אותו דבר גם עם האות החדש, לכן לא נרצה לשנות את הסף γ .

שאלה 3 (30 נקודות)

נוסעים מגיעים לתחנת אוטובוס לפי תהליך פואסון $N(t)$ עם פרמטר λ (בזמן $t = 0$ התחנה ריקה). בזמנים t_1, t_2, t_3 הגיעו אוטובוסים לתחנה כאשר $t_3 > t_2 > t_1 > 0$ ידועים. כאשר הגיע אוטובוס, כל הנוסעים שהיו בתחנה באותו זמן עלו עליו (אין הגבלה על מקומות הישיבה). נסמן ב M_i את מספר הנוסעים שעלו על האוטובוס ה- i , כלומר:

$$\begin{aligned}M_1 &= N(t_1) \\M_2 &= N(t_2) - N(t_1) \\M_3 &= N(t_3) - N(t_2)\end{aligned}$$

1. מהו הפילוג המשותף של שלושת המשתנים האקראיים M_1, M_2, M_3 ?
2. בהינתן שעל שני האוטובוסים הראשונים עלו k נוסעים ($M_1 + M_2 = k$), מצאו משערך MMSE למספר האנשים שעלו על שלושת האוטובוסים ($M_1 + M_2 + M_3$).
3. בהינתן שעל שני האוטובוסים הראשונים עלו k נוסעים, (א) מצאו את ההסתברות שעל האוטובוס הראשון עלו k_1 נוסעים בהינתן שעל שני האוטובוסים הראשונים עלו k נוסעים, כלומר חשבו $P(M_1 = k_1 | M_1 + M_2 = k)$ (ב) מצאו משערך MMSE למספר האנשים שעלו על האוטובוס הראשון (M_1)

פתרון

1. בתהליך פואסון אינטרוולים לא חופפים הם בלתי תלויים סטטיסטית, ולכן ההתפלגות המשותפת היא מכפלת ההתפלגויות:

$$\begin{aligned}P(M_1 = k_1) &= \frac{(\lambda t_1)^{k_1}}{k_1!} e^{-\lambda t_1} \\P(M_2 = k_2) &= \frac{(\lambda t_2 - \lambda t_1)^{k_2}}{k_2!} e^{-\lambda(t_2 - t_1)} \\P(M_3 = k_3) &= \frac{(\lambda t_3 - \lambda t_2)^{k_3}}{k_3!} e^{-\lambda(t_3 - t_2)}\end{aligned}$$

$$\begin{aligned}P(M_1, M_2, M_3) &= P(M_1) P(M_2) P(M_3) = \frac{(\lambda t_1)^{k_1} (\lambda t_2 - \lambda t_1)^{k_2} (\lambda t_3 - \lambda t_2)^{k_3}}{k_1! k_2! k_3!} e^{-\lambda t_1} e^{-\lambda(t_2 - t_1)} e^{-\lambda(t_3 - t_2)} \\&= \frac{(\lambda t_1)^{k_1} (\lambda t_2 - \lambda t_1)^{k_2} (\lambda t_3 - \lambda t_2)^{k_3}}{k_1! k_2! k_3!} e^{-\lambda t_3}\end{aligned}$$

עבור $k_1, k_2, k_3 > 0$ כאשר אם אחד מהם קטן מ-0 ההסתברות היא 0.

2. משערך ה MMSE נתון ע"י

$$E[M_1 + M_2 + M_3 | M_1 + M_2 = k] = k + E[M_3 | M_1 + M_2 = k]$$

הוא נשים לב ש M_3 לא תלוי ב M_1 ו M_2 ולכן

$$E[M_1 + M_2 + M_3 | M_1 + M_2 = k] = k + E[M_3] = k + \lambda(t_3 - t_2)$$

3. משערך ה MMSE נתון ע"י:

$$E[M_1 | M_1 + M_2 = k] = \sum_{k_1=-\infty}^{\infty} k_1 P(M_1 = k_1 | M_1 + M_2 = k) =$$

כעת נשים לב ש עבור $0 \leq k_1 \leq k$ מקבלים:

$$\begin{aligned} P(M_1 = k_1 | M_1 + M_2 = k) &= \frac{P(M_1 = k_1, M_2 = k - k_1)}{P(M_1 + M_2 = k)} = \frac{P(M_1 = k_1) P(M_2 = k - k_1)}{P(M_1 + M_2 = k)} \\ &= \frac{\frac{(\lambda t_1)^{k_1} (\lambda t_2 - \lambda t_1)^{k-k_1}}{k_1! (k-k_1)!} e^{-\lambda t_2}}{\frac{(\lambda t_2)^k e^{-\lambda t_2}}{k!}} = \frac{k!}{k_1! (k-k_1)!} \frac{(\lambda t_1)^{k_1} (\lambda t_2 - \lambda t_1)^{k-k_1}}{(\lambda t_2)^k} = \\ &= \binom{k}{k_1} \frac{(\lambda t_1)^{k_1}}{(\lambda t_2)^k} (\lambda t_2 - \lambda t_1)^{k-k_1} = \binom{k}{k_1} \frac{(\lambda t_1)^{k_1}}{(\lambda t_2)^{k_1} (\lambda t_2)^{k-k_1}} (\lambda t_2 - \lambda t_1)^{k-k_1} \\ &= \binom{k}{k_1} \left(\frac{t_1}{t_2}\right)^{k_1} \left(\frac{t_2 - t_1}{t_2}\right)^{k-k_1} = \binom{k}{k_1} \left(\frac{t_1}{t_2}\right)^{k_1} \left(1 - \frac{t_1}{t_2}\right)^{k-k_1} \end{aligned}$$

כלומר קיבלנו התפלגות בינומית עם פרמטרים $k, \frac{t_1}{t_2}$.

4. משערך ה MMSE נתון ע"י:

$$E[M_1 | M_1 + M_2 = k] = \frac{t_1}{t_2} k$$

מכיוון שהתוחלת של משנה בינומי היא np